2026《数据挖掘》课程 · 探索性实验

景区游览指南的程序性知识挖掘

实验项目 1：景区指南数据采集与预处理

—— 长隆 • 广州白云山 • 武功山（小组汇总）

课程名称： 数据挖掘

实验项目： 项目 1 景区指南数据采集与预处理

覆盖景区： 长隆 / 广州白云山 / 武功山

小组成员： _____（组长） _____ _____

学号 / 班级： _____ _____

提交日期： 2026 年 11 月

本报告整合三位成员采集的长隆、白云山、武功山数据；各景区分册见对应目录。

摘　要

本报告整合长隆、广州白云山、武功山三个景区的官方推荐路线与游客游记，共 29 条记录：官方路线 12 条、游客游记 16 篇、站点攻略 1 条，有效 28 条。三个景区均满足“官方路线≥1、有效游客游记≥3”。原始 32218 字，清洗后 29866 字，整体删除率 7.30%；统一为 24 列字段，输出 CSV / Excel / JSONL，并给出各景区数量、缺失、重复与格式一致性检查。

关键词：三景区；数据采集；文本清洗；数据质量；可复现

一、任务理解与数据来源

1.1 项目要求

项目 1 要求准备 3 个景区的官方推荐路线与游客游记，完成去 HTML/元数据/特殊字符、统一空白等清洗，输出含来源、景区、文本类型、原始内容等字段的结构化文件，并检查数量、缺失、重复与格式一致性。评分侧重数据准备（20 分）、清洗实现（40 分）、结构化输出与质量验证（25 分）、报告与可复现性（15 分）。

1.2 三景区数据来源

表 1-1　三景区数据来源与数量

景区	记录数	官方路线	游客游记	站点攻略	来源站点
长隆	8	3	5	0	Trip.com、长隆官网
广州白云山	7	3	3	1	去哪儿、小红书、白云山官网
武功山	14	6	8	0	8264 户外论坛、搜狐号、简书、萍乡武功山景区官网、豆瓣小组

长隆 8 条由长隆负责人按本地历史数据集转换入库（官方 3 + 游记 5）；武功山 14 条为本人已完成的数据集；白云山 7 条由本人代整理（官方 3 + 游记 3 + 站点攻略 1），待白云山负责人复核。白云山原“官方路线”是景区指南首页，不是具体线路，因此补采了官网“游览推荐”A/B/C 线；补采页面的 URL 与 SHA256 记录在 `scenic/baiyunshan/data/raw/sources.csv`。

二、采集与整合方案

2.1 原始材料盘点

整理前组员的平台 CSV 共 23 条，字段只有 6 列（景区/类型/标题/来源链接/采集时间/正文）。长隆已由负责人按本地历史数据集转换为 8 条标准数据；白云山的“官方路线”是景区指南首页，不是具体线路，去哪儿页面属于平台 SEO 攻略，不是个人游记。按 `docs/01_统一规范.md` 的口径，白云山改用官网 A/B/C 线，去哪儿记录改标为 `站点攻略`，无正文的小红书笔记剔除。

2.2 补采官方路线

表 2-1　补采的白云山官方路线页面

记录 ID	景区	标题	来源	发布日期
BYS-0-01	广州白云山	白云山游览线路（A 线）	白云山官网	2020-06-29
BYS-0-02	广州白云山	白云山游览路线（B 线）	白云山官网	2020-08-18
BYS-0-03	广州白云山	白云山游览路线（C 线）	白云山官网	2020-08-18

2.3 统一字段与编号

三景区统一为 `docs/统一规范.md` 的 24 列：前 9 列（doc_id、scenic_area、doc_type、title、source_site、source_url、raw_content、clean_content、is_valid）为合并必需字段。doc_id 使用“景区码-0/T-两位序号”，doc_type 只允许“官方路线 / 游客游记 / 站点攻略”三种；去哪儿内容统一标为 `站点攻略`，不冒充个人游记。



图 1　三景区数据整合流程

三、数据清洗实现

3.1 平台噪声与小红书正文截取

组员的小红书 CSV 把整页文本（顶部导航、推荐流、笔记头、评论）都放进了“正文”。直接清洗会把推荐流的标题当成游记，因此先以笔记标题最后一次出现为锚点，截到“猜你想搜/评论/编辑于”等结束标记；标题后没有正文的记录（纯图片/视频笔记）直接判为空并从主表剔除。

```
t = re.sub(r"\s*-\s*小红书\s*$", "", title).strip()
idxs = [i for i, ln in enumerate(lines) if ln == t or (len(t) > 8 and t in ln)]
start = idxs[-1] + 1          # 最后一次出现 = 笔记头
for j in range(start, len(lines)):
    if lines[j] in XHS_STOP or lines[j].startswith("猜你想搜"):
        end = j; break
body = [ln for ln in lines[start:end] if ln and not ln.startswith("#")]
```

3.2 清洗规则（R1 – R8）

表 3-1　三景区统一清洗规则

编号	问题	处理方法	示例/效果
R1	HTML 残留	删除标签与实体，块级元素转换行	官网正文保留分段
R2	站点噪声	行级正则删除导航、按钮、版权、购票控件、日期行	删除噪声行 83 行
R3	链接/联系方式	删除 URL、邮箱；以链接为主的行整行删除	删除链接 1 个
R4	表情/异常符号	删除 emoji、零宽字符、控制符；键帽数字还原	删除表情 263 个
R5	空白/换行	统一换行、压缩空格、去连续空行	段落数稳定
R6	标点/字符宽度	全角字母数字转半角、合并重复标点、去汉字间空格	统一全半角
R7	重复段落	完全重复 + 相似度≥0.90 去重	删除重复段 2 段
R8	编码/空值	删除 U+FFFD；作者/日期缺失写“未知”	6/4 条缺失已标注

3.3 关键代码

```
def clean_text(raw, doc_type):
    text, stats = strip_noise_lines(raw)      # 菜单/平台页脚/URL/emoji
    text = normalize_punctuation(text)        # 空白、标点、全半角
    text, dup = dedupe_paragraphs(text)       # 完全重复 + 相似度≥0.90
    return {..., "clean_hash": sha1(去空白 text)}
```

平台噪声规则包括：官网菜单行（“首页 / 走进云山 / 景区动态…”）、购票控件行（“立即购票/选择地区/游玩日期”）、去哪儿“• 广州• 行程攻略• 发布时间”、小红书页脚（“首页/直播/发布/通知/消息/我”、备案号、行吟信息科技等）。

四、结构化输出

4.1 字段与文件

24 列字段与组内规范完全一致，既保留 `raw_content` 供复核，也提供 `clean_content` 供项目 2、3 直接读取；`clean_hash` 用于跨景区去重，`is_valid`/`quality_flags` 保留质量信息。

表 4-1　主要输出文件

文件	内容	用途
scenic/changlong/data/processed/changlong_guides.csv	长隆 8 条（24 列）	景区交付/复查
scenic/baiyunshan/data/processed/baiyunshan_guides.csv	白云山 7 条（24 列）	景区交付/复查
scenic/wugongshan/data/processed/wugongshan_guides.csv	武功山 14 条（24 列）	景区交付/复查
scenic/summary/data/三景区汇总数据集.csv	29 条合并数据	总报告/后续项目
scenic/summary/outputs/三景区景区指南数据集.xlsx	7 个工作表	提交/答辩
scenic/summary/outputs/三景区质量检查.md	数量/缺失/重复/格式	质量验证

4.2 数据样例

官方路线（CL-O-01，清洗后节选）：

嗨！各位快乐玩家，欢迎来到广州长隆度假区，快收下这份吃住玩一站式度假攻略，一键开启快乐假日吧！
第一站：长隆欢乐世界
假期想狂欢？那就来广州长隆欢乐世界！忘掉工作的繁忙和生活的琐碎，来一场全身心的狂欢刺激之旅吧。这里有全球领先的 70+游乐设施，有趣，好看又刺激，让你心跳加速尽情释放！
坐上“全球过山车之王“的垂直过山车。三分钟之内让你完成上天入地冲浪的刺激体验
坐上游乐园最大的秋千，挑战地心引力 在超级大摆锤的极致摇摆中，感受无尽的刺激和乐趣
谁说欢乐世界只适合大朋友，这里有小朋友也能玩的飞马家庭过山车，刺激又奇幻……

游客游记（BYS-T-02，清洗后节选）：

广州周末去哪儿？

5 块钱就能爬的国家 5A 级景区，真的香

整理了 3 条路线+隐藏机位，看完不迷路

基础信息

门票：进山 5 元，

学生半价开放：南门/西门 24 小时

交通：地铁 11 号线“云台花园站”

C1 口步行 5 分钟到南门

3 条路线怎么选？

休闲入门线（带娃/懒人首选）

```
南门→云台花园→缆车上山→山顶广场→摩星岭 3-4 小时 | 索道单程 25 元

经典全景线（深度玩家）

西门→桃花涧→黄婆洞水库→明珠楼→摩星岭→南门 3-4……
```

五、数据质量验证

5.1 数量与最低要求

表 5-1　各景区数量与最低要求

景区	记录数	官方路线	游客游记	有效游记	是否达标
长隆	8	3	5	5	是
广州白云山	7	3	3	3	是
武功山	14	6	8	7	是

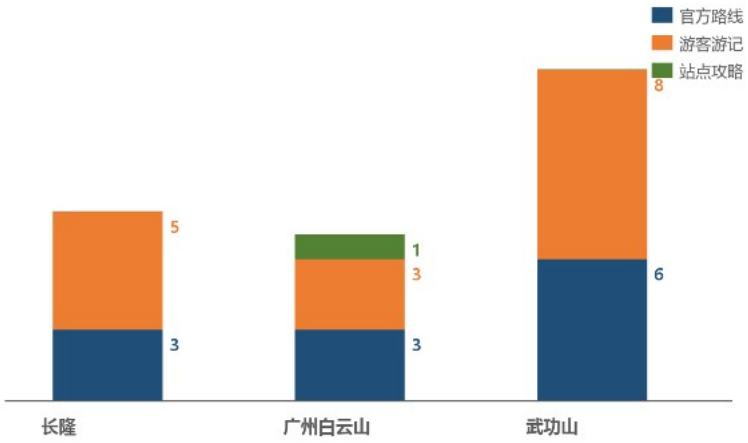


图 2　三景区记录构成

5.2 长度与清洗效果

三景区原始 32218 字，清洗后 29866 字，整体删除率 7.30%；删除噪声行 83 行、表情 263 个、重复段落 2 段。删除比例不高，说明正文抽取已去掉大部分框架，清洗主要起精修作用。

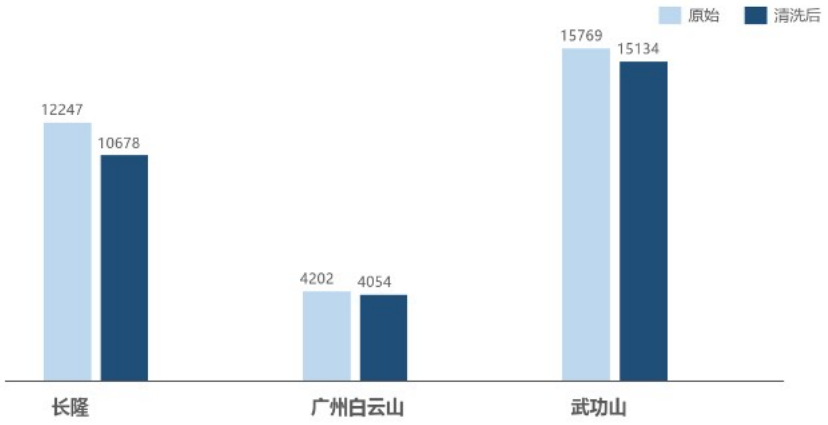


图 3　各景区清洗前后字数

5.3 完整性、重复与格式

表 5-2　完整性检查

景区	作者缺失	日期缺失	重复记录	字段数
长隆	0	0	0	24
广州白云山	4	4	0	24
武功山	2	0	0	24

全表 29 条：doc_id 唯一且符合 `^[A-Z]{2,5}-[OT]-\d{2}$`，doc_type 仅取三种允许值，`clean_content` 无空值，`clean_hash` 无重复，24 列与统一规范一致，编码 UTF-8-SIG。作者缺失 6 条、日期缺失 4 条，主要来自白云山/武功山原始页面，统一写“未知”并打质量标记，没有伪造。

5.4 发现的问题与处理

表 5-3　主要问题与处理

问题	表现	处理	结果
小红书纯图片	标题后无文字正文	按标题锚点截取；空记录剔除	剔除 2 条纯图片/视频记录
去哪儿属性	平台 SEO 攻略	标为站点攻略，不计入游客游记	不冒充个人游记
白云山官方路线	原为景区指南首页	补采官网 A/B/C 线	官方路线 3 条
长隆官方路线	负责人已提供 3 条官网行程	转换入库，不重复补采	官方路线 3 条
日期缺失	采集时间≠发布时间	写“未知”，不伪造	4 条已标注

5.5 与评分细则的对应

表 5-4　评分细则对应关系

考核项	分值	对应证据	完成情况
数据准备与来源规范	20	3 景区/29 条；来源表 1-1；官方补采表 2-1；24 列字段	达成
数据清洗与预处理实现	40	R1－R8 + 平台规则；小红书正文截取；空值/重复处理；代码	达成
结构化输出与质量验证	25	CSV/Excel；表 5-1/5-2；质量报告与前后对比	达成
报告与可复现性	15	依赖/命令/路径；代码片段；问题表 5-3	达成

六、可复现性说明

6.1 环境与命令

- Python 3.11+（实测 3.12）；pandas、openpyxl、lxml、python-docx。
- 合并/质检/报告生成脚本在 `scenic/summary/src/`；三个景区的数据由各自目录维护，本报告只读 `clean_content`。

```
cd scenic/summary
python src/build_summary.py           # 三景区合并 + 统计
python src/qc_summary.py              # 质量检查 + Excel
python src/make_summary_figures.py    # 插图
python src/build_summary_report.py    # 本报告
python ../../checks/check_scenic.py data/三景区汇总数据集.csv
```

6.2 输入输出

表 6-1　主要输入输出

环节	输入	输出
补采	白云山官网 A/B/C 线 URL	scenic/baiyunshan/data/raw/sources.csv
构建	scenic/changlong、baiyunshan、wugongshan 的 24 列 CSV	scenic/summary/data/三景区汇总数据集.csv
质检	三景区汇总数据集.csv	三景区质量检查.md、Excel、统计摘要.json
报告	CSV/统计/插图	项目 1_三景区…docx/pdf

6.3 局限

- 小红书采集依赖登录态，部分纯图片笔记无正文，已剔除；复现时需重新登录。
- 去哪儿页面是平台编辑攻略，按统一规范标为站点攻略，不伪造个人游记。
- 作者/发布日期缺失较多，是原始页面限制；报告如实标注，不做推断。
- 长隆/白云山官方页面可能改版，补采脚本按当前结构定位；改版后需调整 XPath。

七、小结

本报告把三个景区的已冻结数据整合为 29 条、24 列的统一数据集：长隆 8 条、白云山 7 条、武功山 14 条，官方路线 12 条、游客游记 16 篇（有效 15 篇）、站点攻略 1 条；三个景区均达到“官方路线≥1、有效游客游记≥3”。相比简单拼接，本方案保留原始内容与清洗统计，对空文本、平台噪声、小红书整页文本、官方路线缺失等问题都有明确处理记录，可直接支撑项目2、3。

附录 A　数据来源

完整 29 条 URL 见 `三景区汇总数据集.csv` 的 `source_url` 列；下表列出补采的白云山官方路线。

记录 ID	来源链接
BYS-O-01	https://www.baiyunshan.com.cn/bys/lytj/202006/64091ad56c74407f8475ae9ff2de3f81.shtml
BYS-O-02	https://www.baiyunshan.com.cn/bys/lytj/202008/a1dc4c2358d140059126c530847e1c0b.shtml
BYS-O-03	https://www.baiyunshan.com.cn/bys/lytj/202008/e988337476ac4eef9b978956f0845c9a.shtml

组员原始采集脚本与结果在 `archive/legacy_collect_2026-10-28/`；武功山分册见 `scenic/wugongshan/report/`，长隆分册见 `scenic/changlong/README.md`。